

Agrupamento de cores utilizando Mapas Auto-Organizáveis de Kohonen

Gabriel C. Fermino¹, João L. Reolon¹, Taylor B. Schinvelski¹

¹Centro de Ciências Exatas e Tecnológicas (CCET) –
Universidade Estadual do Oeste do Paraná (UNIOESTE) – Cascavel – PR – Brasil

`gabriel.fermino@unioeste.br, joao.reolon@unioeste.br,`
`taylor.schinvelski@unioeste.br`

Abstract. *This article describes the construction and concepts of an Artificial Neural Network with the self-organized Kohonen map implemented in the R language to group nearby colors according to their values in the RGB system.*

Resumo. *Este artigo descreve a construção e conceitos de uma Rede Neural Artificial com o mapa auto organizado de Kohonen implementado na linguagem R para agrupar cores próximas de acordo com seus valores no sistema RGB.*

1. Introdução

O sistema Red-Green-Blue(RGB) foi criado coma a ideia de um sistema aditivo, ou seja, as cores primarias (vermelho, verde e azul) são combinadas para formar novas cores. No nosso contexto utilizamos um sistema RGB onde cada uma das 3 cores possui 256 tonalidades variando entre 0 e 255, gerando assim um conjunto de aproximadamente 18 milhões de cores (17.977.600).

O objetivo final é conseguir agrupar essas cores semelhantes através de um aprendizado não supervisionado. Para isso utilizando a linguagem de programação R, implementaremos uma rede neural artificial, mais especificamente um mapa Auto-Organizáveis de Kohonen.

2. Redes Neurais Artificiais (RNA's)

Este capítulo tratará da ferramenta utilizada para a realização deste trabalho, para construir um sistema capaz de agrupar cores semelhantes, com base em seus atributos na escala *Red-Green-Blue*(RGB). O foco será na compreensão dos mapas auto-organizáveis, pois eles são a base para o entendimento do Mapa Auto-Organizável de Kohonen.

2.1. Mapas Auto-Organizáveis

Os Mapas Auto-Organizáveis são baseados em Aprendizagem Competitiva, ou seja, os neurônios de saída competem entre si para serem ativados ou disparados. Um neurônio de saída que vence a competição é nomeado um *neurônio vencedor* e, como o resultado da competição gera apenas um neurônio vencedor por grupo, este neurônio estará ligado em um instante de tempo [Haykin 2001].

Em um mapa auto-organizável, os neurônios estão colocados em nós de uma grade, correntemente uni ou bidirecional [Haykin 2001], onde vetores de pesos localizam os neurônios no espaço de entrada. Os dois modelos mais conhecidos são o de

Willshaw-von der Malsburg, que é especializado em mapeamentos onde as dimensões de entrada e de saída são as mesmas, e o Kohonen que é um modelo de propósito geral. Para a realização deste trabalho optou-se pela utilização dos mapas auto-organizáveis de Kohonen.

2.2. Mapas Auto-Organizáveis de Kohonen

O modelo introduzido por Kohonen, em meados de 1982, consiste em um mapa topológico artificial que captura as características essenciais do cérebro, mas sem o intuito de explicar detalhes neurobiológicos [Haykin 2001].

Os Mapas Auto-Organizáveis de Kohonen possuem duas camadas: A primeira é a camada de entrada e a segunda, uma camada de saída, que é geralmente organizada com a topologia de uma grade bidimensional ou tridimensional. A Figura 1 apresenta um exemplo de uma grade bidimensional.




Figura 1. Topologia de um Mapa Auto-Organizável de Kohonen com saída bidimensional [Gabriel et al. 2002]

Os mapas auto-organizáveis de Kohonen funcionam, de forma resumida, da seguinte maneira: quando um padrão de entrada x é apresentado, a rede procura o neurônio mais “parecido”, ou mais próximo com x . Durante seu treinamento, a rede aumenta a semelhança do neurônio escolhido e de seus vizinhos com o padrão x . Desta forma, a rede constrói um mapa topológico em que os neurônios que estão topologicamente próximos respondem de forma semelhante a padrões de entrada semelhantes. Nos mapas auto-organizáveis de Kohonen neurônios ativos apresentam conexões mais fortes com neurônios que estão fisicamente mais próximos.

Três processos essenciais estão envolvidos no algoritmo responsável pela formação do mapa auto-organizável:

1. Competição: Para cada padrão da entrada, os neurônios da grade calculam seus respectivos valores de uma função discriminante;

2. Cooperação: O neurônio vencedor determina a localização espacial de uma vizinhança topológica de neurônios excitados, fornecendo assim a base para cooperação entre os neurônios vizinhos;
3. Adaptação Sintática: Permite que os neurônios excitados aumentem seus valores individuais da função discriminante em relação ao padrão de entrada. A função é descrita como:

$$w_j(n+1) = w_j(n) + \alpha(n)h_{j,i(x)}(n)(x(n) - w_j(n)) \quad (1)$$

3. Implementação

Para a implementação de um mapa auto-organizável do Kohonen capaz de agrupar cores semelhantes de acordo com seus valores na escala RGB e os de seus vizinhos, fez-se uso da linguagem de programação R, utilizando a biblioteca própria para mapas de Kohonen, por intermédio do software RStudio.

Por se tratar de um mapa auto-organizável, o sistema conta com duas camadas: uma para a entrada e uma para a saída. A camada de entrada é composta por um matriz de dimensão $n \times 3$, onde n é valor de amostras. Cada linha da matriz receberá três valores contidos em um intervalo de $[0:255]$, e posteriormente os valores contidos nessa matriz serão utilizados na criação de mapas com o intuito de treinar a rede neural.

A camada de saída é composta por um mapa bidimensional composto por *pixels*, que equivalem aos neurônios, com uma topologia hexagonal, onde cada neurônio terá 6 vizinhos ao seu redor, mesmo que ele esteja na borda do mapa, pois devido ao formato toroidal, os neurônios de uma borda se conectam com os neurônios presentes na outra extremidade. A quantidade de neurônios que cada dimensão do mapa terá está ligada diretamente a quantidade de amostras de entrada e segue a seguinte fórmula:

$$gridsize = ceiling(sample.size^{(1/2.5)}) \quad (2)$$

Portanto, por se tratar de um mapa bidimensional, tem-se que a quantidade total de neurônios pode ser definida de acordo com a seguinte função:

$$totalneurons = gridsize^2 \quad (3)$$

Para treinar a rede neural utiliza-se 150 épocas de treinamento, onde em cada época a rede recebe um exemplo distinto de mapa de cores. A taxa de aprendizagem de cada neurônio decresce a cada época no intervalo de $[0.05, 0.01]$ utilizando uma função de vizinhança do tipo *bubble* onde todos os neurônios são atualizados uniformemente. A figura 2 apresenta um exemplo de mapa usado no treinamento.




Figura 2. Exemplo de mapa usado para treinar a rede neural

4. Resultados e Discussões

Após o treinamento extraí-se as informações da rede para gerar o mapa onde as cores estão agrupadas com suas semelhantes. A figura 3 apresenta um exemplo de mapa construído após o treinamento.




Figura 3. Mapa construído após o treinamento

Por se tratar de uma rede neural que agrupa cores tendo como base os seus atributos, não existem classes fixas, pois todos os valores utilizados são gerados aleatoriamente a cada nova execução. Por esse motivo, tecnicamente não existem erros e acertos, sendo impossível calcular a acurácia da implementação assim como a construção de sua matriz de confusão. De mesma forma, encontraram-se também adversidades causadas por essa falta de padrão na análise de desempenho, pois ao gerar um novo conjunto de valores a cada nova execução cria-se uma extrema dificuldade para adquirir o conhecimento de quais parâmetros foram mais eficientes.

Referências

Gabriel, M. C. A. F. et al. (2002). Análise da utilização de redes de kohonen no auxílio ao diagnóstico de doenças reumatológicas.

Haykin, S. (2001). *Redes neurais: princípios e prática*. Bookman Editora.